MEOW 金融时序预测 2.0

西北工业大学计算机学院课程《模式识别与机器学习》

Final Project

课程代码：U10M11170.04

课程主讲老师：朱艺宁

一、背景介绍

传统金融理论普遍认为市场中金融资产的价格遵循随机游走（Random Walk）假说，即其价格的变化是不可预测的。然而也有许多研究交易的从业者认为股票价格的波动存在规律性，即根据历史数据我们可以一定程度上预测未来的价格变动。这两种不同的观点逐渐演变为两个不同的流派，即“Q 宗”（Q-quant）和“P 宗”（P-quant），Q-quant 主要通过利用风险中性测度和无套利原则来对金融资产进行定价，并追求完美对冲各种风险。他们主要服务于投资银行，也就是我们经常听到的金融市场中的“卖方”。P-quant 预测金融资产未来的价格变化，并利用量化交易的经典风险因子模型实现统计套利，他们是金融市场中的“买方”，常见于各种私募公司或自营交易部门。

事实上，由于金融数据普遍易于获取，数据分析技术早在上世纪 70 年代就在金融行业中开始流行。早期的理论普遍采用统计学中的经典线性回归模型（及其变种），该模型认为股票价格的变动受到很多不同因子的影响，且总回报率（return）等于不同因子的回报率乘以权重之后的线性加和。该方法至今仍然占据主流地位，因为线性模型具有良好的“可解释性”，而可解释性对于交易策略的复盘和分析具有重要作用，且线性多因子模型在不断的发展和更新中变得非常的成熟和模块化。近年来，部分从业者开始使用机器学习中的非线性模型替代传统的统计学模型，并取得了很好的效果。与传统的线性模型相比，梯度决策树、神经网络等模型可以更好的学习到数据中的非线性关系，目前业界已经越来越多得采用以神经网络为代表的非线性模型。

二、项目介绍

和其他机器学习任务（比如视觉，推荐，NLP）不同的是，股票价格预测往往不追求过高的准确率。这是因为首先金融数据中充满了各种不同的随机噪声（或者可以理解为无法预测的因子）；其次股票价格时间序列往往是 non-stationary，及其波动率会随着时间变化。然后股票价格回报率的分布一般不满足高斯分布，而属于某种长尾分布。这些统计特征使得我们在预测股价回报率的时候不会有特别高的准确率。一般来说，我们预测的准确率和我们预测的时间长度成反比，也就是说预测时间的越短，准确率越高。在本项目中，我们提供大约 300 只股票从 2023 年 6 月 1 日至 2023 年 12 月 31 七个月的分钟级数据，预测的长度（forecast horizon）为 12 分钟，即预测 12 分钟后的价格变化率：

$$fret12 = \frac{P_{12} - P_0}{P_0}$$ ，

其中，P_0是股票当下的价格，P_{12}为 12 分钟以后的股票价格。

项目整体自由度较高，和常见的预测类任务相同，我们一般把流程分为**数据分析，特征挖掘，模型定义，结果评价**等几个常见环节。由于任务量比较大，我们推荐大家组队进行，但是希望组内每个成员都可以参与到整个项目的所有环节，而不是只负责某个特定的环节。

三、打分标准

指标	**总分**
预测结果整体评价	30
项目报告完整度	20
方案汇报：评价维度	50
---大模型创新性调用（提示：例如 Agent 自动生成因子挖掘？）	
---特征挖掘、特征工程（提示：EDA，特征选择等）	
---模型定义、选择与创新设计（提示：如增量式更新、概率建模、最新时序预测文章的方法调用）	
---组内贡献度评价（提示：重要评分依据）	

项目总分为 100 分。

1. 预测评价

我们使用三个不同的指标来综合评价最终预测结果的好坏（权重各占三分之一）。我们会给出所有 Team 的预测结果排名，其中排名靠前的 team 可以获得这部分的满分。

1. Mean Squared Error (MSE)

$$\frac{1}{N}\sum_{i=1}^{N}(y_i' - y_i)^2$$

2. Pearson Correlation

$$\frac{\sum_{i=1}^{N}((y_i' - \bar{y'})(y_i - \bar{y}))}{\sqrt{\sum_{i=1}^{N}(y_i' - \bar{y'})^2}\sqrt{\sum_{i=1}^{N}(y_i - \bar{y})^2}}$$

3. R Squared

$$1 - \frac{MSE(model)}{MSE(baseline)} = 1 - \frac{\sum_{i=1}^{N}(y_i - y_i')^2}{\sum_{i=1}^{N}(\bar{y_i} - y_i')^2}$$

*where y_i' is the predicted value and y_i is the ground truth for each observation **i**.*

TIPS1: 一般来说这三个指标中，MSE 比较低的话，其他两个指标也会不错。当然同学们在选取 loss function 时可以使用但不局限于 MSE。不同的 loss function 会使模型表现出不同的效果。

TIPS2：从业人员经常使用 Pearson Correlation（或其变种）作为对比指标。这里可以给大家一个参考：项目原始代码使用 6 个简单特征和 Ridge 线性回归模型得到的预测结果的 correlation 仅仅为 2%-3%。业内一些顶级的团队的预测结果的 correlation 可以到 20%-30%甚至以上（当然他们使用的数据种类可能更为丰富）。我们对大家的能做到的预期为 5%-10%。如果能超过 10%则会有比较多的加分。

TIPS3: 一般来说要想达到比较好的效果，我们需要几十上百个特征，并结合合理的模型才有机会做到。我们推荐大家使用神经网络这一类非线性模型，一般来说他们的表现会比简单的线性模型好，这是因为我们很难在特征中去体现数据中的非线性关系。但是如果特征本身足够好，能够抓住数据中的非线性关系的话，使用简单的线性模型也可以达到较好的效果。总结来说，特征或者模型，两者中必须有一个做的很优秀才能实现较好的预测结果，如果都很优秀的话就有机会接近业内水平。

2. 方案汇报分数

- **预测结果整体评价**：预测结果整体评价时会对所有的特征和模型进行排名，排名靠前的会得到较高的分数。
- **创新性评价：** 方案评价时还会评估特征和模型的“稀有性”。举例说明，如果多个 team 都挖掘出了同一个或者十分类似的特征，或者模型的结构一样或者类似，那么其获得的方案评价分数也会由于稀释效应而降低。
- **贡献度评价：**你对小组作业方案评价体系内的贡献程度，注意仅整理报告、汇报方案，无实质性贡献会大大降低个人评分。
- **探索度评价：**做了一些有趣的尝试，即使没有产出很好的结果，得到老师认可亦可以提高评分，请在课堂展示时充分说明。

3. 项目报告完整度评价

1. 请介绍对原始数据分析之后得到的初步结果和思路。
2. 请详细阐述特征挖掘的思路，即每一个特征是如何产生的，是有背后的逻辑还是是通过一些随机的排列组合产生的。
3. 使用什么模型？模型定义的思路？比如：是否在定义模型过程中进行了一些有意义的尝试（不一定是最终的模型但是对思路有所启发的）、为什么采用这个模型，优缺点的权衡、是否使用什么独特的思路训练的模型等。如参考引用了较新的论文所提方法，会有额外加分，可以在报告中注明引用。
4. 请不要在项目报告内大量粘贴代码，如果有必要只需说明文件名+类/方法名即可。

4. 代码规范评价

代码风格应和项目原始代码类似，或者参考 Google 风格指南



https://zh-google-styleguide.readthedocs.io/en...

https://zh-google-styleguide.readthedocs.io/en/latest/google-py...

本项目并不严格要求大家遵循某个指南，但是对于以下几个点会重点关注：

考察点	正确	错误
运算符两边加空格	a = b + c	a=b+c
逗号后加空格	x = f(a, b) x = [1, 2, 3]	x=f(a,b) x=[1,2,3]

类名/方法名含义清晰，类名首字母大写，函数/方法名首字母小写	class MeowEngine(object):
	def fit(self, xdf, ydf):
		class meow_engine(object):
		def Fit(self, xdf, ydf):
		class X(object): (含义不清)
		def abc(x): （含义不清）

关于注释：请勿过分注释；请勿无效注释。不同于其他开源项目开发中详细的注释风格，此项目中由于授课老师和助教是大家代码最终的阅读者，理想状态下阅读者应该可以直接从文件名，类名，方法名了解到该类是什么，该方法具体要做什么。我们鼓励零注释或仅在必要地方注释。鼓励代码风格简单紧凑和模块化。

四、必要基础知识

1. 什么是 Order Book

一个 OrderBook 是一个包含了所有交易者订单信息的集合。想买的 order 叫做 bid order，想卖

的 order 叫做 ask order，这些 bid 和 ask 的 order 一旦满足了各自的条件就会完成配对，产生一笔交易。我们假设所有的订单都有一个限价，即买单有一个不高于的价格，卖单有一个不低于的价格。OrderBook 上面 bid 和 ask 有很多不同的价位，每个价位记录了该价位包含订单的总数量，例如下图是某股票某时刻的 orderbook5 档之内的 snapshot：

卖5	20.36	183
卖4	20.35	319
卖3	20.34	138
卖2	20.33	72
卖1	20.32	244
买1	20.31	346
买2	20.30	629
买3	20.29	254
买4	20.28	345
买5	20.27	71

2. 市场事件 (Add, Trade, Cxl)

举例说明，每天股票市场开盘之后，连续竞价阶段，当投资者想要买入某个股票时，他会确定买入的限价和数量，并将这个交易指令发给证券交易所。此时一个新的订单事件（Add event）就产生了。如果 OrderBook 上面有合适的对手盘（即有人也想在这个价位或者更低的价位卖出），两个订单就会撮合并产生成交，此时一个新的成交事件就产生了（Trade event）。如果没有合适的对收盘，或者订单没有成交完，这个订单或者其剩余部分就会留在 OrderBook 上面，找到对应的价位排好序，等待对手盘的出现。如果在这个订单完全成交完之前，投资者想要取消订单，就会发送一个取消指令给交易所，这个时候就会产生一个撤单事件（Cancel event，也写作 Cxl event）。

3. 主买主卖

Add event 可以细分为 add buy event 和 add sell event，分别对应买和卖。同理 Cxl event 也可以分为 cxl buy event 和 cxl sell event。但是对于一个成交事件（trade event）来讲，其中必然有一个买单和一个卖单，我们如何理解数据中的“trade buy”和“trade sell”的概念？举例说明，当一个卖单找不到对手盘而停留在 OrderBook 上等待时，假如这个时候出现了一个新的条件合适的买单并和该卖单成交，我们就称这个交易事件为 trade buy event，这是因为在这两个一买一卖的订单中，买单主动“击中”了卖单，显得更为主动。如果上面例子反过来就是 trade sell event。

4. 市场微观结构

市场微观结构（market microstructure）是指资产交易价格形成与发现的过程与运作机制。市场微观结构和股票短期价格波动之间有着千丝万缕的联系。充分理解并研究市场微观结构有助

于我们从本质上理解短期价格波动的原因，并找到其中的规律，总结出优秀的特征。

5. 动量和反转

动量效应（Momentum effect）一般又称惯性效应，是指股票的收益率有延续原来的运动方向的趋势，即过去一段时间收益率较高的股票在未来获得的收益率仍会高于过去收益率较低的股票。反转效应（Reversal effect）是指在一段较长的时间内，表现差的股票在其后的一段时间内有强烈的趋势经历相当大的逆转，要回复到正常水平（reversal to mean），而在给定的一段时间内，最佳股票则倾向于在其后的时间内出现差的表现。

一般我们用来模型预测的特征都可以归类于动量类或者反转类，或在不同条件下表现不同。但令人惋惜的是，传统涨跌幅因子的反转效应并非一直稳定。动量与反转的本质是股价对信息的反应程度。实证发现股票成交量大、大单占比高的涨跌幅统计学上表现为反转，而成交量小、小单占比高的统计学上表现为动量。动量与反转，只是涨跌幅因子呈现于表面的一种现象，其背后的本质，其实是不同的投资者交易行为，导致股票价格对市场信息的反应程度不同，即究竟是反应不足，还是反应过度。若反应不足，则股票当前的价格走势在未来仍有一定的延续性，涨跌幅因子表现为动量；若反应过度，则涨跌幅因子应当表现为反转。而成交量的大小也好，大小单的交易占比也罢，都只不过是衡量、或者干脆说是推测股价反应程度的线索。

五、数据定义

下表给出了数据中部分列的定义，其他未给出的列的定义可以很容易通过已给出定义的列推断出来。

symbol	股票代码
interval	时间(milli-seconds)
fret12	Forward return in 12mins。股票 12 分钟之后的价格变化。是本项目中我们需要预测的值 y。fret12 = (midpx.shift(-12) - midpx) / midpx
midpx	当前中间价格, midpx = (bid0 + ask0) / 2
lastpx	当前 interval 最后一个成交价
open	当前 interval 第一个成交价
high	当前 interval 最高成交价
low	当前 interval 最低成交价
bid0	买一价格
bsize0	买一数量

ask0	卖一价格
asize0	卖一数量
bid4	买五价格
ask4	卖五价格
bsize0_4	买一到买五 5 档总数量
asize0_4	卖一到卖五 5 档总数量
btr0_4	买一到买五每档（数量 x 价格）的和（即总金额）
atr0_4	卖一到卖五每档（数量 x 价格）的和（即总金额）
nTradeBuy	当前 interval 的主买交易事件的个数
tradeBuyQty	当前 interval 的主买交易事件的总数量
tradeBuyTurnover	当前 interval 的主买交易事件的总金额
tradeBuyHigh	当前 interval 的主买交易事件的最高成交价
tradeBuyLow	当前 interval 的主买交易事件的最低成交价
buyVwad	当前 interval 的买单从下单到成交的时间的加权平均（权重为数量）

六、数据/项目初始代码下载

项目数据集下载：

https://kaggle.com/datasets/8f59f523259ba610...
https://kaggle.com/datasets/8f59f523259ba61071b5c2d97c7752...

项目初始代码下载：

https://gitee.com/n8y3s/meow
https://gitee.com/n8y3s/meow

七、项目代码提交

请将项目文件打包成 zip 文件发送至课程邮箱 ml_course2025@163.com

- 请勿包含数据或者模型缓存文件，仅需打包必要的代码和项目报告即可。

- 项目报告应包括：方法介绍、数据分析、创新点说明、结果分析与总结、成员分工说明。
- 参考项目初始代码运行方式，我们会更改你所提交的代码中的数据文件路径，然后直接使用

```
$ python meow.py
```

来运行代码。因此对项目的入口处的代码请保持和初始代码同样的风格。我们所使用的用来训练和评估预测结果的数据和项目中提供的数据集格式完全一致。

环境要求

- Python >= 3.8。

注意事项

1. 禁止抄袭代码。我们会对所有提交的代码进行相似度检测，并对相似度高的 team 成员面试。注意：代码重命名，重构，添加冗余代码/注释等操作不能降低相似度！
2. 每组不多于 5 人，请在报告中明确每一位成员的分工，明确所提创新点的贡献者。
3. 注意不要 overfit。我们用来最终评价结果的数据集和项目提供的数据集完全没有重合，因此请大家注意确保自己的模型不要出现严重的 overfit 问题。
4. 如果有对这个方向非常感兴趣并且想要在这个方向学习到更多知识的同学可以联系助教同学。