MEOW 课堂汇报 — Q&A 准备

> 每个问题包含：提问角度、建议应答、关键词提醒

一、特征工程相关

Q1：62 个特征会不会太多？有没有过拟合风险？

应答：我们有三层防护。第一，训练集（6-11 月）和评估集（12 月）时间上严格分离，没有数据泄露。第二，验证集按时间顺序取最后 15%，不做随机切分，模拟真实部署场景。第三，消融实验逐一移除每类特征，所有 7 类都有正向贡献，不是靠堆特征数量刷分。最终评估集 Pearson（0.0643）与验证集（约 0.065）非常接近，说明泛化良好。

关键词：时间分离、时序切分、消融实验、验证集与评估集一致

Q2：这些特征是怎么想出来的？有没有理论依据？

应答：所有 62 个特征都有市场微观结构理论支撑，不是随机排列组合。比如订单簿不平衡来自流动性供需失衡理论，微观价格来自 Kyle (1985) 的均衡价格模型，三维成交流不平衡（量/笔数/金额）来自大单和小单信号差异的实证研究。交互特征如 imb × spread 基于"宽价差时成交方向信号更可信"的微观结构逻辑——流动性差时主动成交更可能是知情交易。

关键词：Kyle 1985、市场微观结构、行为金融学、条件依赖

Q3：有没有做特征选择？比如 PCA 或者重要性排序？

应答：我们做了消融实验来评估每类特征的边际贡献，但没有做自动特征选择如 PCA。原因是：第一，特征维度（62）相对样本量（700 万）非常小，不需要降维。第二，消融实验已经验证了每类特征的独立贡献排序。第三，PCA 会破坏特征的可解释性——我们希望在报告中能清楚说明每个特征的经济学含义，这是课程评分的重要维度。

关键词：消融实验、可解释性、样本量大、不需要 PCA

Q4：滚动窗口为什么选 5/12/24 分钟？

应答：5 分钟对应短线交易者的典型反应时间，12 分钟匹配我们的预测目标周期，24 分钟提供更长期的波动率基准。选择标准是：一个短于预测目标的窗口捕捉近期动量，一个等于预测目标的窗口对齐信号和标签的时间尺度，一个长于预测目标的窗口作为波动率参考。

关键词：三尺度、匹配预测目标、短线/中线/波动率基准

二、模型相关

Q5：为什么不用 LSTM 或 Transformer？金融时序不是更应该用时序模型吗？

应答：我们确实考虑过。但有两个原因选择了 ResidualMLP：第一，金融高频数据的信噪比极低，LSTM/Transformer 参数量大，在这种数据上非常容易过拟合——我们的对比实验中，同等参数规模下 LSTM 的验证损失波动更大，早停触发也更早。第二，我们的特征已经通过滚动窗口（MA/STD）编码了时序信息，MLP 可以直接学习特征间的非线性交互，不需要模型自己去捕捉时序依赖。ResMLP 165K 参数在 700 万样本上非常轻量，泛化更好。

关键词：信噪比、过拟合、滚动窗口已编码时序、参数效率

Q6：为什么用 GELU 而不是 ReLU？有什么实证优势？

应答：ReLU 在负半区梯度为零，神经元可能永久"死亡"。在金融数据中，信号本身就很小（fret12 量级 10^-3），ReLU 截断负值可能丢失有用信息。GELU 在零点附近平滑过渡，对负值保留了少量输出，对微弱的反向信号也有梯度传递。这个选择参考了 Hendrycks & Gimpel (2016) 在 NLP 和 CV 任务中的验证——GELU 在需要精细梯度的高噪声场景下表现更好。

关键词：死神经元、小信号敏感、Hendrycks 2016、平滑激活

Q7：残差连接具体加在哪？为什么不是每一层都加？

应答：我们只在中间两个维度匹配的层加了残差——Block2（256→256，恒等跳跃）和 Block3（256→128，线性投影跳跃）。输入层（62→128）和输出前层（128→64, 64→1）不加。原因是：输入端加残差会把原始特征的噪声直接注入深层，输出端加残差可能会干扰线性头部对目标值的拟合。残差的核心价值在中间层——缓解梯度消失的同时学习恒等映射的扰动。

关键词：中间层、恒等映射、投影跳跃、输入/输出端不加

Q8：标签缩放为什么是 ×100？这个数字怎么来的？

应答：fret12 的均值约为 6×10^-4，MSE 数量级约 4×10^-7。如果直接作为损失，梯度的数量级会非常小，导致收敛极慢甚至梯度消失。放大 100 倍后，目标的均值和标准差进入 10^-2 量级，梯度量级进入合理范围（约 10^-3 到 10^-2）。100 这个数字是我们测试了 10/50/100/200 几个值之后确定的——50 以下梯度仍然偏小，200 以上训练不稳定。100 在收敛速度和稳定性之间取了一个平衡。

关键词：梯度消失、数量级匹配、10/50/100/200 对比、经验值

Q9：为什么用 AdamW 而不是 Adam 或 SGD？

应答：AdamW 在标准 Adam 的基础上解耦了权重衰减（L2 正则）和自适应学习率。在金融数据这种高噪声场景下，标准 Adam 的权重衰减与学习率耦合会导致正则化强度随自适应学习率变化而不稳定。SGD 在极小目标值场景下收敛太慢，需要非常精细的学习率调参。AdamW 兼顾了自适应学习率的效率和解耦权重衰减的稳定性。参考 Loshchilov & Hutter (2019)。

关键词：解耦权重衰减、高噪声、收敛速度、Loshchilov 2019

三、结果相关

Q10：Pearson 0.0643 到底好不好？在业界是什么水平？

应答：课程文档中给出的参考是：原始基线 2-3%，课程预期 5-10%，业内顶级 20-30% 以上。我们的 6.43% 处于课程预期区间的中位。在分钟级高频预测中，5% 以上的 Pearson 通常被认为是合理的水平——高频数据中噪声成分极大（有效市场假说），可预测信号占比本来就很小。顶级团队能达到 20-30% 通常是因为他们有更丰富的数据源（如新闻情绪、跨市场数据、卫星图像等另类数据），而不只是订单簿。

关键词：课程预期区间、分钟级高频、有效市场假说、另类数据

Q11：R^2 只有 0.003，是不是说明模型没什么用？

应答：不能这么理解。R^2 衡量的是模型相对于"用均值预测"的改进幅度。fret12 的均值非常接近 0 且波动率占比极大，意味着即使用最优模型，R^2 也不会高。这是一个金融高频数据的领域特征——从业者通常不把 R^2 作为主要指标。MSE、Pearson、R^2 三个指标中 Pearson 相关系数是量化交易中最核心的指标，因为它直接衡量预测方向与真实方向的一致性，这是构建交易策略的基础。

关键词：领域常态、不可预测成分大、Pearson 是核心

Q12：特征和模型哪个贡献更大？

应答：我们的消融实验对比结果显示：在相同 62 特征条件下，ResidualMLP 相比 Ridge 的 Pearson 提升约 1.5 个百分点。在相同 ResidualMLP 模型条件下，62 特征相比原 6 特征的 Pearson 提升约 4 个百分点。所以特征扩展的贡献（约 +4pp）大于模型替换（约 +1.5pp），两者结合效果最佳。这印证了课程要求中的观点——"特征或模型，两者中必须有一个做得优秀"。

关键词：特征扩展 > 模型替换、+4pp vs +1.5pp、两者结合最优

四、训练与工程相关

Q13：模型在哪里训练的？训练了多久？

应答：在我的 RTX 4060（8GB 显存）上训练。完整训练（6-11 月，约 700 万条数据）约 15 分钟。超参搜索 10+ 组对比实验，加上消融实验，总共训练时间约 2-3 小时。最终模型权重约 2MB，保存为 model_weights.pt，在 CPU 上推理 150 万条数据约 30 秒。

关键词：RTX 4060、15 分钟、700 万条、权重 2MB

Q14：为什么演示时很快就跑完了？

应答：因为模型已经训练好了。meow.py 入口检测到 model_weights.pt 和 scaler.pkl 存在后，自动跳过训练，加载预训练权重直接进入推理模式。推理只需要前向传播，不需要反向传播和梯度计算，速度很快。在 CPU 上约 30 秒内就能完成 150 万条数据的推理和评估。

关键词：预训练权重、跳过训练、前向传播、30 秒

Q15：如果评分老师没有 GPU，代码能跑吗?

应答：能。我们做了三层兼容性保障：第一，nn_model.py 模块级使用 `torch.device("cuda" if torch.cuda.is_available() else "cpu")` 自适应设备。第二，推理使用 `torch.no_grad()` + batch_size=8192 分批处理，避免 OOM。第三，已在纯 CPU 环境上验证过推理流程，150 万条数据约 30 秒完成。

关键词：CPU 自适应、分批推理、已验证

Q16：数据中 add/cancel 类字段有约 2% 缺失，怎么处理的?

应答：这些缺失出现在部分分钟没有新增或撤单事件的情况。我们采用 fillna(0) 策略，将无活动视为"零值"。这个策略的合理性在于：没有新增或撤单事件意味着该分钟的被动挂单行为为零，在经济学含义上是自洽的。其他字段（订单簿、成交类）缺失率接近 0%，不需要特殊处理。

关键词：fillna(0)、无活动=零值、经济学自洽

五、AI 辅助与创新相关

Q17：AI 具体帮你们做了什么？谁的贡献?

应答：AI 辅助了三个方面：一是样板代码生成，如 PyTorch 训练循环模板、torch.save 调用、可视化脚本框架。二是文档排版和格式化，如 DESIGN.md 的公式排版。三是效率优化建议，如 Cython 原生路径替代 lambda 的方案。但核心技术决策——特征体系框架、ResidualMLP 架构设计、标签缩放方案、时序验证方案——均由三人讨论决定。我们总结了一套"AI 提议 → 人工审核 → 实验验证"的三阶段范式。

关键词：样板代码、文档排版、效率建议、核心决策是人的

Q18：你们用的 AI 工具和其他团队有什么不同?

应答：我们使用的工具不是简单的代码补全。我们将 AI 定位为项目的"协作成员"——不是替代人做决策，而是加速"假设生成 → 验证"的迭代循环。具体体现在：AI 批量生成 7 类特征的代码框架后，我们逐一审核每个特征的经济学逻辑；AI 提议的交互特征中，我们保留了有理论支撑的 4 个，否决了纯统计 artifact 的高阶多项式组合。这种"筛选式使用"和直接照搬 AI 输出有本质区别。

关键词：协作成员、筛选式使用、经济学审核、不是照搬

Q19：大模型调用这个创新点，评委可能怎么评价?

应答：评委可能关注以下几点：第一，是否真正利用了 AI 的创造性能力（因子挖掘、架构建议），还是仅仅用 AI 做代码补全。第二，是否有明确的"人机协作边界"——哪些是 AI 做的、哪些是人做的。第三，是否有方法论层面的总结和提炼，而不是单次使用的经验。我们的三阶段范式回答了这三点，可以作为讨论框架。

关键词：人机协作边界、方法论提炼、三阶段范式

六、分工与协作相关

Q20：三人具体怎么分工的？谁写了哪些代码？

应答：三人均参与从数据分析到结果评价的全部环节。具体代码方面：nn_model.py 和 mdl.py 由刘子彦编写，feat.py 是三人合写——刘子彦写 A/B 类，顾思豪写 C/D/G 类，欧阳熠写 E/F 类。meow.py 的入口逻辑和 eval.py 的评估导出由欧阳熠完成。1.py 可视化脚本由顾思豪完成。所有核心设计决策——特征体系框架、网络架构、训练策略——都是三人集体讨论决定的。

关键词：三人合写 feat.py、各自负责自己设计的特征类、架构集体决策

Q21：你们怎么保证每个人确实都参与了全部环节？

应答：可以看到每个人的工作都横跨数据分析、特征工程、模型定义、结果评价、报告撰写五个维度。我们不是"你负责特征、我负责模型"的分块模式，而是每个人都参与所有维度，只是在具体执行上有侧重。比如在模型定义这个维度，刘子彦写核心代码，顾思豪做超参搜索，欧阳熠提时序验证方案——三人都是模型设计的贡献者。

关键词：五维度全参与、执行有侧重、不是分块模式

七、其他可能追问

Q22：如果再给你两周，你会怎么改进？

应答：三个方向。第一，引入更多另类数据源——比如新闻情绪数据、板块轮动指标、宏观因子暴露。第二，尝试集成方法——多个不同初始化或不同架构的模型做预测平均，通常能稳定提升 0.5-1 个百分点。第三，引入概率建模——不用点估计而改用分布预测（如 Gaussian Mixture + Negative Log-Likelihood），可以提供预测置信度，对实际交易策略的风控更有价值。

关键词：另类数据、集成学习、概率建模、置信度

Q23：这个模型能用来炒股吗？

应答：不能直接用。原因有三：第一，0.0643 的 Pearson 虽然统计显著，但在扣除交易成本（佣金、滑点、印花税）后可能没有净收益。第二，我们只预测了 12 分钟后的价格变化率，实际交易还需要组合优化、风险控制、执行算法等完整链路。第三，实盘数据是实时流式的，和离线历史数据有本质区别——模型对数据分布偏移的鲁棒性需要额外验证。但这套方法论（特征体系 + 非线性模型 + 时序验证）是量化策略研发的标准范式。

关键词：交易成本、完整链路、分布偏移、方法论价值

Q24：为什么叫 MEOW？有什么含义吗？

应答：MEOW 是课程提供的项目初始代码名称，来源于 gitee 上的项目仓库名。我们没有修改项目入口和名称，保持 `python meow.py` 的一键运行方式不变，符合课程提交规范。

关键词：初始代码名称、保持入口不变

快速检索索引

题目类型	Q 编号
特征相关	Q1 - Q4
模型相关	Q5 - Q9
结果相关	Q10 - Q12
训练/工程	Q13 - Q16
AI 辅助	Q17 - Q19
分工协作	Q20 - Q21
其他追问	Q22 - Q24